Technische Universität Braunschweig

A Branch-and-Bound Method for Bilevel Parallel Machine Scheduling with Adversarial Job Selection

Master Thesis Presentation

Ole Damke, April 2026
Institut für Mathematische Optimierung
Technische Universität Braunschweig

Gliederung

- Motivation & Problem
- Branch-and-Bound-Algorithmus
- Die Ceiling-Schranke
- Die Max-LPT-Schranke
- Frühzeitige Optimalitätserkennung
- Numerische Experimente
- Fazit

Motivation

Szenario: Produktionsbetrieb

- Manager entscheidet, welche Aufträge angenommen werden (Budgetbeschränkung)
- Planer weist Aufträge Maschinen zu — minimiert die Fertigstellungszeit
- Manager benötigt eine Worst-Case-Garantie für den Makespan

Dies ist ein **zweistufiges Optimierungsproblem**:

- **Leader** (Manager): wählt Aufträge zur Maximierung des Makespans
- **Follower** (Planer): minimiert den Makespan

Unser Problem

Obere Ebene (Leader)
Unbeschränktes Knapsack-Problem

↓ Auftragsportfolio

Untere Ebene (Follower)
Paralleles Maschinenplanungsproblem ($P||C_{max}$)

Zweistufige Optimierung: Definition

Zweistufiges Optimierungsproblem

$$\max_{x} \quad F\big(x,\ y^*(x)\big) \qquad\qquad x \in X$$

$$\text{wobei} \quad y^*(x) \in \arg\min_{y} \{f(x, y) : y \in Y(x)\}$$

- **Leader** wählt x unter Antizipation der optimalen Reaktion des Followers
- **Follower** beobachtet x und minimiert sein eigenes Ziel
- **Optimistisch:** bei Indifferenz des Followers wird das für den Leader günstigste Ergebnis gewählt

Zweistufige Optimierung: Schwierigkeit

Rechenkomplexität

Zweistufige Optimierung ist im Allgemeinen NP-schwer [Frangioni 1995].

Unsere spezifische Herausforderung

- **Leader** löst ein unbeschränktes Knapsack-Problem (NP-schwer)
- **Follower** löst paralleles Maschinenplanungsproblem $P||C_{max}$ (NP-schwer)
- Wertfunktion $C^*_{max}(x)$ ist nicht-konvex und unstetig. Kein geschlossener Ausdruck für $C^*_{max}(x)$: jede Auswertung erfordert das Lösen des Follower-Problems, was kombinatorische Verfahren (z. B. Branch-and-Bound) auf der oberen Ebene notwendig macht

Konsequenz

Allgemeine zweistufige Löser (z. B. MibS) können nur sehr kleine Instanzen verarbeiten. Wir benötigen einen **problemspezifischen exakten Algorithmus**.

Das Knapsack-Scheduling-Problem

Problemdaten:

- n Auftragstypen, m identische Parallelmaschinen, Budget $B > 0$
- Auftragstyp i: Bearbeitungszeit $d_i > 0$, Kosten $p_i > 0$; oBdA $d_1 \geqslant \cdots \geqslant d_n$
- **Leader** wählt $x_i \in \mathbb{Z}_+$ Kopien von Typ i; **Follower** weist $y_{ik} \in \mathbb{Z}_+$ Aufträge von Typ i Maschine k zu

Vollständige zweistufige Formulierung

$$\begin{aligned} \max_{x \in \mathbb{Z}_+^n} \quad & C^*_{max}(x) \\ \text{s.t.} \quad & \textstyle\sum_{i=1}^n p_i x_i \leqslant B \end{aligned}$$

$$\text{wobei} \quad C^*_{max}(x) = \min_{y_{ik} \in \mathbb{Z}_+} \max_{k=1,\dots,m} \sum_{i=1}^n d_i y_{ik}$$

$$\text{s.t.} \quad \textstyle\sum_{k=1}^m y_{ik} = x_i \quad \forall\, i \in \{1, \dots, n\}$$

Leader **maximiert** $C^*_{max}(x)$; Follower **minimiert** es — eine adversarielle zweistufige Struktur.

Warum Enumeration Scheitert

Naiver Ansatz: alle zulässigen x aufzählen und für jedes das Follower-Problem lösen.

$$\text{Suchraum} \leqslant \prod_{i=1}^{n} \left(\left\lfloor \frac{B}{p_i} \right\rfloor + 1 \right)$$

Beispiel: $n = 10$, $B = 100$, $p_i = 5+i$

Obere Schranke: $\mathbf{5{,}29 \times 10^{10}}$ Kandidaten

Bei 1 ms pro Follower-Lösung: $\approx \mathbf{1{,}68}$ Jahre

Lösung: Branch-and-Bound mit engen oberen Schranken zur aggressiven Baumbereinigung.

Suchbaumstruktur

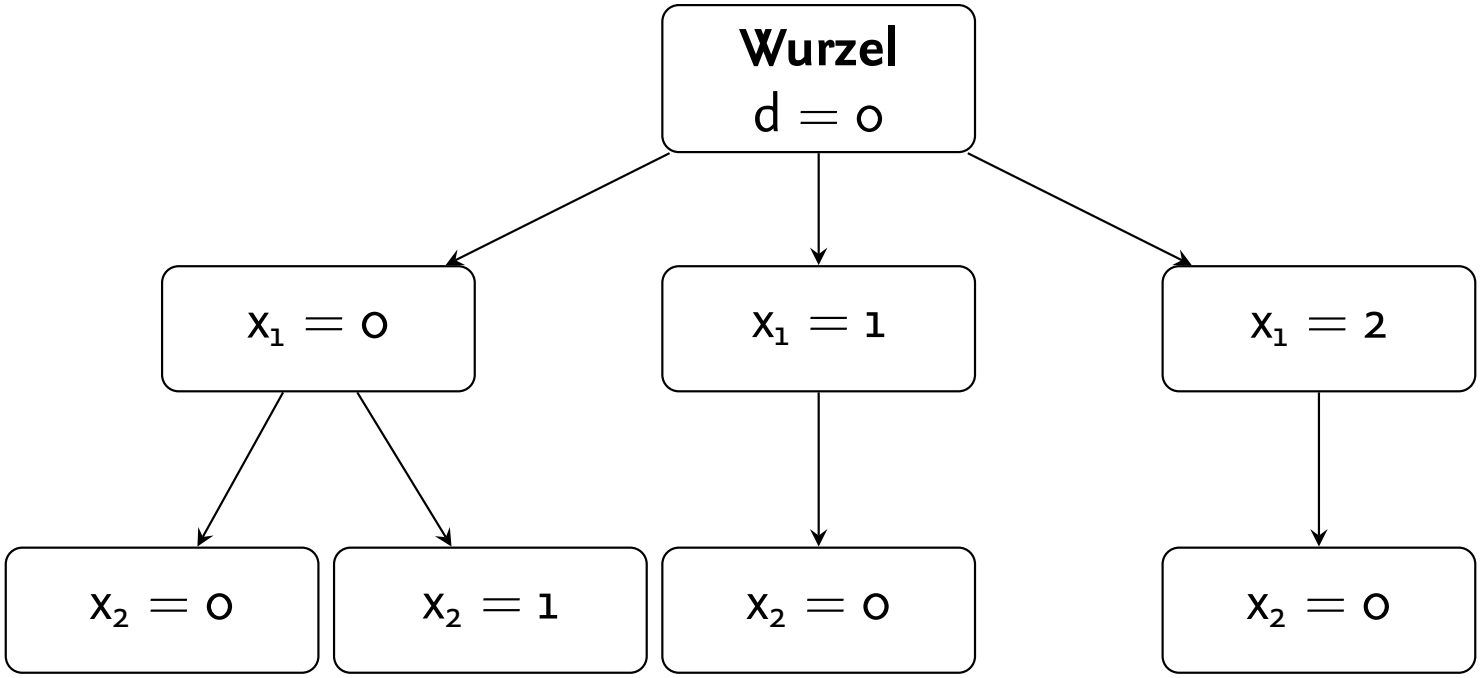

Beispiel: $n = 2$ Typen, $p_1 = 5$, $p_2 = 8$, $B = 10$

Jedes **Blatt** erfordert eine Follower-Lösung (Scheduling). Bei großem n und B hat der Baum Milliarden von Blättern $\Rightarrow$ nicht handhabbar.

Branch-and-Bound: Überblick

Knotenstruktur auf Tiefe d

- **Fixierte Entscheidungen:** $x_1, \ldots, x_d$ $\quad B_{\text{rest}} = B - \sum_{i=1}^{d} p_i x_i$
- **Maschinenlasten:** inkrementeller LPT-Plan für Elemente $1, \ldots, d$
- **Kinder:** $x_{d+1} = 0, 1, \ldots, \lfloor B_{\text{rest}} / p_{d+1} \rfloor$

Drei Komponenten:

1. **Branching** — fixiere x_d
2. **Bounding** — berechne $\mathrm{UB}(d, B_{\text{rest}})$
3. **Pruning** — verwerfe wenn $\mathrm{UB} \leqslant C_{\max}^{\text{ink}}$

Designentscheidungen:

- Tiefensuche $\rightarrow$ schnelle Kandidatenaktualisierung $\rightarrow$ aggressives pruning
- Inkrementelles LPT: $O(m)$ pro Knoten
- DP vorberechnet: $O(1)$ Schrankenabfragen

Die LPT-Regel — Heuristik des Followers

Longest Processing Time (LPT) [Graham 1969]:

- Aufträge nach nicht-aufsteigender Dauer sortieren
- Jeden Auftrag der am wenigsten belasteten Maschine zuweisen

Garantie: $C^*_{\max}(x) \leqslant C^{\mathrm{LPT}}_{\max}(x) \leqslant \frac{4}{3} C^*_{\max}(x)$

Inkrementelle Aktualisierungen

Verzweigung $d \to d{+}1$: x_{d+1} Aufträge der Dauer d_{d+1} anhängen. Bestehenden sortierten Maschinenbelastungszustand wiederverwenden — **keine vollständige Neuberechnung**

LPT-Algorithmus

$L_1 = \cdots = L_m \leftarrow 0$
für jeden Auftrag j (nicht-aufsteigende Reihenfolge):
  $k^* \leftarrow \arg\min_k L_k$
  $L_{k^*} \leftarrow L_{k^*} + d_j$
return $C^{\mathrm{LPT}}_{\max} = \max_k L_k$

Zeit: $O(J \log m)$

Praxis: LPT ist in $\approx 84,6\%$ unserer Testinstanzen optimal.

Beschneiden durch Obere Schranken

Auf Tiefe d mit Budget B_{rest} berechnen wir eine obere Schranke:

$$C^*_{\max}(x_1, \ldots, x_n) \leqslant \mathrm{UB}(x_1, \ldots, x_d, B_{\text{rest}}) \quad \forall\, x_{d+1}, \ldots, x_n \text{ (Ergänzungen)}$$

prunen, wenn $\mathrm{UB} \leqslant C^{\text{ink}}_{\max}$.

$$\mathrm{UB} = \underbrace{C^{\mathrm{LPT},(d)}_{\max}}_{\text{fixiert, } 1..d} + \max_{\sum_{i>d} p_i y_i \leqslant B_{\text{rest}}} \underbrace{\Delta(y_{d+1}, \ldots, y_n)}_{\text{Mehraufwand Restelemente}}$$

Ceiling-Schranke

$\Delta = \sum_{i>d} d_i \lceil y_i / m \rceil$

Einzelne DP-Tabelle, $O(1)$ Abfrage

Max-LPT-Schranke

$\Delta = C^{\mathrm{LPT}}_{\max}(y_{d+1}, \ldots, y_n)$

DP-Tabelle pro Tiefe, engere Schranke

Ceiling-Schranke: Formulierung

Knapsack-Scheduling-Relaxierung

$$\mathrm{UB} = C_{\max}^{\mathrm{LPT},(d)} + \max_{y \geqslant 0} \sum_{i=d+1}^{n} d_i \left\lceil \frac{y_i}{m} \right\rceil \quad \text{s.t.} \sum_{i>d} p_i y_i \leqslant B_{\mathrm{rest}}$$

Intuition: $\lceil y_i/m \rceil$ Aufträge vom Typ i auf m gleichwertigen Maschinen erhöhen den Makespan um $\lceil y_i/m \rceil \cdot d_i$ — stets eine Überschätzung.

DP-Implementierung — O(1) Abfrage pro Knoten

Reduktion auf unbeschränktes Knapsack-Problem. Für Elementtyp i:

- **Einzel:** Kosten p_i, Wert d_i (für $1, \ldots, m-1$ Kopien)
- **Block:** Kosten $m \cdot p_i$, Wert d_i (für eine Charge von m)

Vorberechnung in umgekehrter Elementreihenfolge $\Rightarrow$ jede Tiefe-d-Abfrage ist ein direkter Tabellenlesezugriff.

Ceiling-Schranke: Korrektheitsbeweis

Satz

Für jede zulässige Vervollständigung gilt: $C^*_{max}(x_1, \ldots, x_n) \leqslant UB$

Beweisschema:

1. $C^*_{max}(x) \leqslant C^{LPT}_{max}(x)$ (LPT überschätzt)
2. Nach fixierten Elementen ist der aktuelle Makespan $= C^{LPT,(d)}_{max}$
3. Annahme: alle Maschinen bis $C^{LPT,(d)}_{max}$ gefüllt — nur Überschätzung
4. Auf m gleichmäßig belasteten Maschinen erhöht das Hinzufügen von y_i Aufträgen vom Typ i den Makespan um $\lceil y_i/m \rceil \cdot d_i$
5. Daher $C^{LPT}_{max}(x) \leqslant C^{LPT,(d)}_{max} + \sum_{i>d} \lceil x_i/m \rceil \cdot d_i$
6. Maximierung der rechten Seite über B_{rest} ergibt $UB \geqslant C^*_{max}(x)$ $\square$

Das Max-LPT-Problem

Definition

Finde $x \in \mathbb{Z}_+^n$ mit $\sum_i p_i x_i \leqslant B$, das $C_{\max}^{\mathrm{LPT}}(x)$ **maximiert.**

Zwei Rollen:

1. Einmalig gelöst $\Rightarrow$ **starker anfänglicher Kandidat** (mit $\frac{3}{4}$-Approximationsgarantie)
2. Für Restelemente an jedem Knoten gelöst $\Rightarrow$ **engere Schranke** als Ceiling

Berücksichtigt die tatsächliche LPT-Struktur (nicht nur $\lceil \cdot / m \rceil$).

Hauptergebnis

Max-LPT **optimal** in $O(n \cdot B)$ per DP gelöst.

Kompromiss

n tiefenspezifische DP-Tabellen vs. eine Ceiling-Tabelle; amortisiert durch besseres pruning.

Approximationsgarantie: Bausteine

Lemma (Eigenschaften der α-Approximation)

Sei $\texttt{approx}$ eine α-Approximation für Minimierung ($\alpha \geqslant 1$), setze $\beta := 1/\alpha$. Dann gilt für alle x:

$$\beta \cdot \mathrm{Opt}(x) \;\leqslant\; \beta \cdot \mathrm{approx}(x) \;\leqslant\; \mathrm{Opt}(x) \;\leqslant\; \mathrm{approx}(x)$$

Satz (Zweistufige Approx. [Weninger & Fukasawa 2025])

Wenn $\beta \leqslant 1$, $\beta \cdot \mathrm{Opt}(x) \leqslant \beta \cdot \mathrm{approx}(x) \leqslant \mathrm{Opt}(x) \leqslant \mathrm{approx}(x)$ für alle x, $\mathrm{approx}(x)$ für das Follower-problem stets zulässig ist und $\hat{x} \in \arg\max_x \mathrm{approx}(x)$, dann:

$$\beta \cdot \mathrm{Opt}_{\text{zweistufig}} \;\leqslant\; \mathrm{Opt}(\hat{x}) \;\leqslant\; \mathrm{Opt}_{\text{zweistufig}}$$

Unser Setting: LPT ist eine $\frac{4}{3}$-Approximation für $P||C_{max} \Rightarrow \beta = \frac{3}{4}$. Max-LPT maximiert $C_{max}^{LPT} \Rightarrow$ Satz direkt anwenden.

Die $\frac{3}{4}$-Approximationsgarantie

Satz

Sei $\hat{x}$ die Max-LPT-Lösung und x^* die zweistufig-optimale Lösung. Dann gilt:

$$\frac{3}{4}\, C^*_{max}(x^*) \;\leqslant\; C^*_{max}(\hat{x}) \;\leqslant\; C^*_{max}(x^*)$$

Beweis (unter Verwendung der zwei Bausteine):

1. **Lemma** ($\alpha = \frac{4}{3}$, $\beta = \frac{3}{4}$): für alle x, $\frac{3}{4}\, C^*_{max}(x) \leqslant \frac{3}{4}\, C^{LPT}_{max}(x) \leqslant C^*_{max}(x) \leqslant C^{LPT}_{max}(x)$
2. $\hat{x}$ maximiert C^{LPT}_{max}, also $C^{LPT}_{max}(x^*) \leqslant C^{LPT}_{max}(\hat{x})$
3. **Satz [WF25]:** $\frac{3}{4} \cdot \mathrm{Opt}_{zweistufig} \leqslant C^*_{max}(\hat{x}) \leqslant \mathrm{Opt}_{zweistufig}$
4. **Vollständige Kette:** $\frac{3}{4}\, C^*_{max}(x^*) \leqslant \frac{3}{4}\, C^{LPT}_{max}(x^*) \leqslant \frac{3}{4}\, C^{LPT}_{max}(\hat{x}) \leqslant C^*_{max}(\hat{x}) \leqslant C^*_{max}(x^*)$ $\square$

Praktische Bedeutung

Der Max-LPT-Kandidat ist **garantiert** $\leqslant 25\%$ **suboptimal**. In der Praxis ist die Lücke praktisch immer null (LPT ist oft optimal).

Max-LPT-Algorithmus: Budget pro Maschine & Eigenschaften

Strukturelle Beobachtung

In jedem LPT-Plan wurde der **zuletzt geplante Auftrag** I auf die **am wenigsten belastete Maschine** zum Planungszeitpunkt gelegt:

$$C_{max}^{LPT} = C_{max}^{(m)} + d_I$$

Der Makespan wird durch die minimale Maschinenlast unmittelbar vor I plus seiner Dauer d_I bestimmt.

Für einen festen Kandidaten-Letzten-Auftrag J wollen wir $C_{max}^{(m)}$ für Elemente $1, \ldots, J$ maximieren.

Zwei Haupteigenschaften des optimalen vorhergehenden Plans

- **Eigenschaft 1** (höchstes Budget pro Maschine):
  $B^* := \lfloor B/m \rfloor$ ist das größte Budget, das gleichmäßig jeder Maschine zugewiesen werden kann.
  Keine Umverteilung kann der am wenigsten belasteten Maschine mehr als B^* geben.
- **Eigenschaft 2** (beste Elemente für B^*):
  Für Budget B^* ist die optimale Elementkombination aus Typen $\leqslant J$ das Optimum des unbeschränkten Knapsack-Problems.

Wenn beide gelten, erzielt kein Plan ein größeres $C_{max}^{(m)}$: kaufe m Kopien jedes DP-optimalen Elements und führe LPT aus.

Budgetanpassung wenn $\hat{B} := B - mB^* < p_J$

Rest $\hat{B}$ ist zu klein, um eine Kopie von J zu bezahlen. Reduziere B^* um 1 (gleichmäßig über Maschinen) bis $\hat{B} \geqslant p_J$. Eigenschaft 1 gilt für das reduzierte B^*; frage $\mathrm{DP}(J, B^*)$ erneut ab. Wenn B^* vor $\hat{B} \geqslant p_J$ null erreicht, überspringe J (unzulässig).

Max-LPT-Algorithmus: Korrektheit & Komplexität

Algorithmus (Pseudocode)

DP-Tabelle vorberechnen (unbeschränktes Knapsack-Problem, Elemente $1 \dots n$, Budgets $0 \dots B$).

$z^* \leftarrow 0$ // bisher bester Kandidat

für jeden Typ $J \in \{1, \dots, n\}$:

  $B^* \leftarrow \lfloor B/m \rfloor$

  solange $(B - mB^*) < p_J$ **und** $B^* > 0$: $B^* \leftarrow B^* - 1$

  $z_J \leftarrow \mathrm{DP}(J, B^*) + d_J$; $z^* \leftarrow \max(z^*, z_J)$

return z^*

Korrektheit

Jede optimale Lösung hat einen letzten Auftrag I.

Für dieses I identifizieren Eigenschaften 1 & 2 einen optimalen vorhergehenden Plan via $\mathrm{DP}(I, B^*)$.

$\max_J z_J$ über alle Kandidaten deckt das Optimum ab. □

Komplexität: $O(n \cdot B)$

DP-Tabelle in $O(n \cdot B)$ vorberechnet.

Pro Kandidat J: $O(1)$ Abfrage + $O(B^*/m)$ Anpassung.

n Kandidaten $\Rightarrow O(n \cdot B)$ gesamt.

Frühzeitige Optimalitätserkennung

Schlüsselungleichung

Für alle x: $C^*_{max}(x) \leqslant C^{LPT}_{max}(x)$ (LPT überschätzt nur)

Sei $\hat{x} \in \arg\max_x C^{LPT}_{max}(x)$. Wenn $C^{LPT}_{max}(\hat{x}) = C^*_{max}(\hat{x})$, dann gilt für alle zulässigen x:

$$C^*_{max}(\hat{x}) = C^{LPT}_{max}(\hat{x}) \geqslant C^{LPT}_{max}(x) \geqslant C^*_{max}(x)$$

$\Rightarrow$ $\hat{x}$ ist das **globale zweistufige Optimum** - kein B&B-Baum erforderlich!

Auswirkung

- $C^*_{max}(\hat{x})$ wird ohnehin berechnet, um den Kandidaten zu initialisieren
- Diese Überprüfung kostet **nichts extra**
- In $\approx$ **84,6**% unserer Testinstanzen ausgelöst $\Rightarrow$ an der Wurzel gelöst

Complete Algorithm

1. Solve Max-LPT $\rightarrow \hat{x}$; compute $C_{max}^{LPT}(\hat{x})$, $C_{max}^{*}(\hat{x})$
2. **If** $C_{max}^{LPT}(\hat{x}) = C_{max}^{*}(\hat{x})$: **return** $\hat{x}$
3. $C_{max}^{ink} \leftarrow C_{max}^{*}(\hat{x})$; push root to stack Q
4. **While** $Q \neq \emptyset$:
   - Remove node $(d, x_1, \ldots, x_d, B_{rest})$
   - If $d = n$: solve follower; update C_{max}^{ink}
   - Else: compute $UB(d, B_{rest})$
   - If $UB \leqslant C_{max}^{ink}$: **prune**
   - Else: push children (depth-first)
5. Return incumbent

Inspired by [Weninger & Fukasawa 2025].

Leaf optimisation

At depth $n-1$: only the child spending maximum remaining budget matters. All others produce a smaller or equal C_{max}^{*}.

Follower solver

Gurobi 12.0.3 [Gurobi Optimization 2024] solves the MIP formulation of $P||C_{max}$ at leaves.

Versuchsaufbau

Hard- & Software:

- AMD Ryzen 5 9600X, 32 GB RAM
- Python 3.11, Gurobi 12.0.3
- Einzelthreadige Läufe

PatternTestSet: 140 Instanzen

7 strukturelle Muster:
Uniform Ratios, High Variance, Increasing, Moderately Random, Extreme, Strong Correlation, Subset Sum

6–12 Typen, 3–8 Maschinen, Budget 15–50

Korrektheit: vs. Enumeration

- 140 Instanzen: **0 Abweichungen**
- Enumeration bei 15/140 Zeitlimit überschritten
- B&B löste alle 140 in ms

Beschleunigung

Bis zu $\mathbf{10^6} \times$ schneller als vollständige Enumeration

Gitternetz-Sensitivitätsanalyse

Gitter: 6×6 (Typen × Maschinen), 3 Budgetmultiplikatoren, 5 Seeds = 540 Instanzen; 1 h Limit.

Typen: 4, 8, 12, 16, 20, 24 • **Maschinen:** 2, 4, 6, 8, 10, 12 • **Multiplikatoren:** 1,3; 2,5; 5,0

Budget ×	Wurzel opt.	Fertiggest.	Zeitüberschr.	Blatt Zeitü.
1,3×	154 / 154	22 / 26	2 / 0	2 / 0
2,5×	150 / 150	19 / 22	3 / 0	8 / 8
5,0×	153 / 153	20 / 23	4 / 1	3 / 3

Ceiling / MaxLPT

Hauptergebnis

84,6% der Instanzen an der Wurzel gelöst — kein B&B-Baum erforderlich

MaxLPT-Vorteil

Mehr Fertigstellungen und weniger Zeitüberschreitungen in jeder Konfiguration

Ceiling vs. MaxLPT: Schwierige Instanzen

61 nicht-wurzeloptimale Instanzen, bei denen beide Schranken innerhalb von 1 h fertiggestellt wurden:

Laufzeit (Ceiling − MaxLPT):

- Mittelwert: +71 s (Ceiling langsamer)
- Median: +0,4 s
- Max: +1.057 s
- MaxLPT schneller: **41 von 61 Fällen**

Knoten (Ceiling − MaxLPT):

- Mittelwert: +4,8 Mio. Knoten
- Median: +69 K
- Max: +54,5 Mio.
- MaxLPT immer weniger Knoten

Interpretation

MaxLPT beschneidet aggressiver bei schwierigen Instanzen. Die Vorberechnung von n DP-Tabellen ist durch die reduzierte Knotenanzahl vollständig gerechtfertigt. Ceiling ist marginal schneller bei trivialen (wurzeloptimalen) Fällen.

Vergleich mit MibS

MibS: allgemeiner zweistufiger MILP-Löser [Tahernejad et al. 2020]
Teilmenge: $m \in \{4, 8, 12\}$, $j \in \{4, 8, 16, 20\}$, 3 Multiplikatoren, 5 Seeds $= 180$ Instanzen

m \ j	4	8	16	20
4	15/15	8/15	2/15	1/15
8	5/15	0/15	0/15	1/15
12	2/15	0/15	0/15	0/15

MibS-Fertigstellungen (von 15) pro Zelle. MaxLPT B&B: **179/180**.

Beschleunigung gegenüber MibS (1 h Limit)

Ceiling: Mittelwert +2.876,6 s, Median +3.599,9 s MaxLPT: Mittelwert +2.959,6 s, Median +3.599,5 s
Probleme, die unser Algorithmus in Millisekunden löst, benötigen bei MibS **über eine Stunde**.

Zusammenfassung & Schlussfolgerungen

Beiträge:

1. Formales zweistufiges Rucksack-Scheduling-Modell
2. Ceiling-Schranke mit vorberechnetem $O(1)$ DP, lösbar in $O(n \cdot B)$
3. Max-LPT optimal in $O(n \cdot B)$ gelöst
4. $\frac{3}{4}$-Approximationsgarantie (Theorie)
5. Frühzeitige Optimalitätserkennung (84,6% an Wurzel gelöst)
6. Umfassende numerische Studie

Übertrifft MibS um **Größenordnungen**.

Einschränkungen

- Keine Charakterisierung einfacher Instanzen
- Nur identische Maschinen

Zukünftige Arbeit

- Verwandte/unverwandte Maschinen
- Wurzeloptimale Instanzen charakterisieren

Vielen Dank!

Fragen?

Ole Damke • o.damke@tu-braunschweig.de

Institut für Mathematische Optimierung • TU Braunschweig

Literatur I

- A. Frangioni. On a new class of bilevel programming problems and its use for reformulating mixed integer problems. Eur. J. Oper. Res., 82(3):615–646, 1995.
- R. L. Graham. Bounds on Multiprocessor Timing Anomalies. SIAM J. Appl. Math., 17(2):416–429, 1969.
- N. Weninger, R. Fukasawa. A fast combinatorial algorithm for the bilevel knapsack problem. Math. Program., 210(1):847–879, 2025.
- S. Tahernejad, T. K. Ralphs, S. T. DeNegre. A branch-and-cut algorithm for mixed integer bilevel linear optimisation. Math. Program. Comput., 12(4):529–568, 2020.
- T. Kleinert et al. A survey on MIP techniques in bilevel optimisation. EURO J. Comput. Optim., 9:100007, 2021.
- S. Dempe, A. Zemkoho. Bilevel Optimization, vol. 161. Springer, 2020.

Literatur II

Gurobi Optimization, LLC. Gurobi Optimizer Reference Manual. Version 12.0, 2024. https://www.gurobi.com